

КУРСОВАЯ РАБОТА

РАЗРАБОТКА ЧАТ-БОТА ДЛЯ ПОИСКА ВАКАНСИЙ

Выполнил:
Киселевский Даниил Андреевич
студент 3 курса специальности
6-05-0611-03 «Искусственный интеллект»
Дневной формы получения образования

Научный руководитель:
Вувуникян Юрий Микиртычевич,
Профессор кафедры фундаментальной
и прикладной математики, доктор
физико-математических наук, профессор

Цель работы и задачи проектирования

Цель работы — исследовать модели семантического поиска и разработать интеллектуальную систему подбора вакансий для рынка труда Республики Беларусь с использованием диалогового интерфейса.

Задачи курсовой работы:

- Изучение теоретических основ информационного поиска и архитектуры RAG (Retrieval-Augmented Generation), объединяющей возможности языковых моделей и внешних баз знаний.
- Проектирование каскада моделей: извлечение семантических фильтров через LLM, взвешенная векторизация текста и доменное ранжирование.
- Программная реализация системы на языке Python с использованием фреймворков FastAPI (Backend) и Streamlit (Frontend).
- Экспериментальная проверка работоспособности чат-бота и оценка качества поиска по метрикам hit@1 и hit@5.

Стек технологий:

- Python
- FastAPI
- Streamlit
- PostgreSQL
- pgvector

Модели поиска:


- LLM + SBERT

Актуальность и проблема «семантического разрыва»

Традиционные механизмы поиска, основанные на точном лексическом совпадении символов, не обеспечивают необходимую полноту выдачи:

- Для классических алгоритмов слова «стажер», «junior» и «начинающий» — это разные токены, хотя они описывают одну и ту же роль.
- Активное использование англицизмов в IT-сфере (напр. «backend» vs «разработчик серверной части») затрудняет поиск по жестким фильтрам.
- Соискатели (особенно начинающие) формулируют запросы в свободной форме (напр. «работа в Гродно на лето без опыта»), не используя специфические профессиональные фильтры.

Решение: переход от поиска по словам к поиску по смысловым векторам в многомерном пространстве.



Теоретические основы: SBERT и RAG


- Sentence-BERT (bi-encoder):
 - Использование нейросетевой модели для генерации векторных эмбеддингов (числовых представлений смысла).
 - Применена компактная мультязычная модель paraphrase-multilingual-MiniLM-L12-v2.
 - Размерность вектора: 384. Сравнение текстов производится через косинусную близость.
- LLM:
 - openai/gpt-oss-120b через API от Groq
 - Использован режим strict mode, который позволяет получить структурированный ответ (structured output) от модели по заранее заданному макету (JSON-schema).

Общая архитектура системы

Программный комплекс спроектирован на основе трёхуровневой архитектуры, обеспечивающей модульность и масштабируемость решения:

- Client (Frontend) реализован на фреймворке Streamlit. Обеспечивает интерактивный диалоговый интерфейс, хранение истории сессии и визуализацию карточек вакансий.
- Server (Backend) высокопроизводительный асинхронный API на FastAPI. Выполняет оркестрацию бизнес-логики: обращение к LLM, управление алгоритмами релаксации и финальное ранжирование.
- Data (Database): реляционная база данных PostgreSQL с расширением pgvector. Позволяет объединить хранение структурированных данных вакансий с возможностью векторного поиска по эмбедам.


Взаимодействие между уровнями осуществляется через REST API с использованием валидации данных через модели Pydantic.



Сбор данных и векторизация вакансий


- Парсинг (Data Acquisition):
 - Автоматизированный сбор данных с портала rabota.by.
 - Сформирован корпус из 1016 вакансий с сохранением структуры: должность, компания, зарплата, опыт, навыки.
- Авторская схема взвешивания (Weighting Scheme):
 - Для борьбы с «размыванием» смысла длинными описаниями применена приоритизация полей.
 - Ключевые поля (название вакансии, навыки) дублируются в итоговой текстовой строке перед векторизацией. Это усиливает их математическое влияние на финальный эмбединг.
- Расчет векторов производится offline, результаты сохраняются в БД

Подготовка данных для векторного поиска ai-job-finder-python



Интеллектуальная обработка: LLM-слой и релаксация

- LLM-интерпретация (NLU):
 - Использование модели через Groq API для преобразования неструктурированного текста пользователя в JSON-объект.
 - Извлекаемые параметры: опыт, график, тип занятости, часы работы, оплата, формат найма и role_keywords (домены)
 - Строгая валидация ответа на соответствие схеме (JSON Schema) перед выполнением запроса к БД.
- Алгоритм адаптивной релаксации:
 - Решение проблемы «нулевой выдачи» при избыточно строгих условиях запроса.
 - Механизм: если по фильтрам найдено 0 вакансий, система пошагово снимает ограничения.
 - Приоритезация: второстепенные фильтры (график, оплата, ...) удаляются первыми, в то время как защищенные ключи (опыт, тип занятости) сохраняются максимально долго.



Гибридное ранжирование: Domain Boost


Одним из ограничений семантического поиска (SBERT) является риск смешения вакансий из разных, но лингвистически похожих областей. Для повышения точности внедрен механизм Domain Boost

- Проблема: Вакансии со схожими описаниями (напр. «менеджер» в IT и «менеджер» в торговле) могут иметь близкие векторы, что приводит к нерелевантной выдаче.
- Решение: Корректировка косинусного расстояния на основе доменных ключевых слов.
- Словари маркеров: система использует предустановленные наборы терминов для ключевых сфер: IT (python, разработчик, ...), HoReCa (бариста, кухня, ...), Логистика (склад, грузчик, ...).
- Результат: Вакансии, соответствующие профессиональному домену запроса, получают «бонус» и поднимаются выше в итоговом списке.

Итоговый пайплайн обработки запроса

Процесс обработки пользовательского ввода представляет собой последовательный каскад алгоритмов, обеспечивающий переход от естественного языка к ранжированной выдаче:

- NLU & Validation: извлечение семантических интенгов через LLM и строгая валидация структуры данных.
- Pre-search Analytics: подсчет потенциального охвата аудитории в БД по жестким критериям.
- Heuristic Relaxation: циклический алгоритм «смягчения» фильтров при дефиците релевантных позиций.
- Vector Retrieval: выполнение семантического поиска в векторном пространстве (pgvector) по отфильтрованному подмножеству.
- Domain Reranking: финальная корректировка позиций на основе профессионального контекста (Domain Boost).



Тестирование: Сценарий поиска работы в сфере общественного питания («Бариста без опыта»)

Ищу работу бариста в сеть кофеен, без опыта



Нашел наиболее релевантные вакансии под ваш запрос.
Найдено вакансий: 2.

Вакансия 1

Бариста

Компания: ИП Христинченко Татьяна Петровна

Зарплата: Не указано

Частота выплат: Не указано

Занятость: Полная занятость

Формат найма: Не указано

График: 3/2 или 2/2

Часы работы: Не указано

Формат работы: На месте работодателя

Опыт: Не требуется

Навыки: Общественное питание, Обслуживание покупателей, Контроль сроков годности

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска в высококвалифицированных IT-доменах («Бизнес-аналитика»)



Хочу работать в сфере разработки ПО или бизнес аналитики, опыта нет



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 1.

Вакансия 1

Бизнес-аналитик/Специалист по внедрению ПО

Компания: ООО МигСофт

Зарплата: От 1 700 Br за месяц на руки

Частота выплат: Два раза в месяц

Занятость: Полная занятость

Формат найма: Не указано

График: 5/2

Часы работы: 8

Формат работы: На месте работодателя или удалённо

Опыт: 1 3 года

Навыки: Деловая коммуникация, 1С: Бухгалтерия, Бизнес-анализ, Аналитическое

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска по специфическим квалификациям и условиям («Водитель с категорией В»)



У меня есть права категории В. Хотел бы работать "на транспорте" – перевозить людей или грузы. График желательно гибкий с почасовой оплатой



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 1.

Вакансия 1

Водитель Такси (Гродно и Гродненская область)

Компания: ООО Матурхан

Зарплата: От 2 000 Br за месяц на руки

Частота выплат: Раз в неделю

Занятость: Полная занятость

Формат найма: Трудовой договор

График: Свободный

Часы работы: Вечерние или ночные смены, 8 или 12

Формат работы: Разъездной, Права категории В

Опыт: Не требуется

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска удаленной работы в IT-сфере («Стажер в IT / Рекрутинг»)



Хочу несложную удаленную работу в IT-сферах: маркетинг, копирайтинг, ... Опыта нет.



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 2.

Вакансия 1

Специалист по подбору персонала в IT сфере (стажер)

Компания: ООО Брайт Эйдженси

Зарплата: От 390 до 650\$ за месяц до вычета налогов

Частота выплат: Не указано

Занятость: Полная занятость

Формат найма: Не указано

График: 5/2

Часы работы: 8

Формат работы: Удалённо

Опыт: Не требуется

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2




Количественная оценка качества поиска

- Методика оценки (Benchmark):
 - Для тестирования подготовлено 16 контрольных запросов, охватывающих типичные сценарии (IT-вакансии, сфера услуг, логистика, студенческие стажировки).
- Используемые метрики:
 - hit@1: наличие релевантной вакансии на первой позиции выдачи.
 - hit@5: наличие хотя бы одной релевантной вакансии в топ-5 результатов.

Итоговые оценки

- hit@1: 14/16 (87.5%).
- hit@5: 15/16 (93.75%).
- Avg Distance (top-1): ≈ 0.5

Качество поиска (Evaluation Tests)



10	Официант или повар без опыта, сменный график	официант, повар	да	да	Официант в ресторан «МАРМО»
11	Водитель категории В, разъездной формат и доставка	водитель	да	да	Водитель категории В (Автолайтэкспресс)
12	Стартовая роль в подборе персонала, IT-сфера, стажировка или junior	подбор, hr, рекрутер, персонал	нет	да	Junior Sales Manager (ООО Сенлайн)
13	Удалённый ассистент интернет-маркетолога, контент и аналитика	ассистент интернет-маркетолога, маркетолог	да	да	Ассистент интернет-маркетолога (Зизор)

Заключение

- Результаты работы:
 - Разработан и протестирован работоспособный прототип чат-бота для поиска вакансий.
 - Реализован полный технологический цикл: от автоматизированного сбора данных с `rabota.by` до семантической интерпретации запросов с помощью LLM.
 - Система успешно решает проблему «лексического разрыва», обеспечивая точность `hit@1` на уровне 87.5%.
- Перспективы развития:
 - Разработка полноценной RAG-системы (добавление модуля `generative`).
 - Интеграция дополнительных источников данных и переход к мультиресурсному поиску.
 - Дообучение (Fine-tuning) моделей эмбеддингов на специфическом корпусе вакансий для лучшего понимания профессиональной терминологии.
 - Внедрение механизма «памяти» модели (сессии/чаты).
 - Добавление списка синонимов.

Спасибо за внимание!