

КУРСОВАЯ РАБОТА ПО УЧЕБНОЙ ДИСЦИПЛИНЕ «МОДЕЛИ РЕШЕНИЯ ЗАДАЧ В ИНТЕЛЛЕКТУАЛЬНЫХ СИСТЕМАХ»

РАЗРАБОТКА ПРОТОТИПА СЕМАНТИЧЕСКОГО ПОИСКА ВАКАНСИЙ С ИСПОЛЬЗОВАНИЕМ ЯЗЫКОВОЙ МОДЕЛИ И ВЕКТОРНЫХ ПРЕДСТАВЛЕНИЙ

Выполнил:
Киселевский Даниил Андреевич
студент 3 курса специальности
6-05-0611-03 «Искусственный интеллект»
Дневной формы получения образования

Научный руководитель:
Вувуникян Юрий Микиртычевич,
Профессор кафедры фундаментальной
и прикладной математики, доктор
физико-математических наук, профессор

Цель работы и задачи проектирования

Цель работы – исследовать модели семантического поиска и разработать интеллектуальную систему подбора вакансий для рынка труда Республики Беларусь.

Задачи курсового проекта:


- Изучение теоретических основ информационного поиска и архитектуры RAG (Retrieval-Augmented Generation). Смешение русской и английской профессиональной терминологии, а также высокая вариативность названий должностей затрудняют поиск для начинающих специалистов.
- Проектирование каскада моделей: взвешенная векторизация текста, LLM-извлечение фильтров и реранжирование.
- Программная реализация системы на языке Python с применением векторной СУБД PostgreSQL / pgvector.
- Тестирование прототипа и экспериментальный анализ качества поиска по метрикам hit@1 и hit@5.

Актуальность и проблематика

Традиционный лексический поиск (по ключевым словам) не обеспечивает высокую полноту выдачи из-за «семантического разрыва»:

- «стажер», «junior», «начинающий» – для алгоритмов это разные слова, хотя смысл один.
- Частое использование англицизмов в IT-вакансиях (например, «backend» vs «разработчик серверной части»).
- соискатели часто пишут общие фразы (например, «работа в Гродно без опыта»), не указывая точное название должности.

Решение – переход от лексического поиска (совпадение символов) к семантическому (сопоставление смысловых векторов в многомерном пространстве).




Теоретические основы: SBERT и RAG

- Sentence-BERT (bi-encoder):
 - Использование нейросетевой модели для получения эмбедингов (числовых векторов).
 - В работе применена модель paraphrase-multilingual-MiniLM-L12-v2.
 - Размерность вектора: 384.
- Косинусная близость:
 - Математическая мера схожести двух векторов.
 - Позволяет найти наиболее близкие по смыслу вакансии, даже если в них нет общих слов с запросом.
- Архитектура RAG (Retrieval-Augmented Generation):
 - Подход, объединяющий поиск в базе знаний (Retrieval) и генеративные способности языковых моделей (LLM).
 - Позволяет системе опираться на реальные данные вакансий, исключая «галлюцинации» нейросети.

Проектирование системы: Общая архитектура

- Трехуровневая программная архитектура:
 - Клиентский слой обеспечивает интерактивное взаимодействие с пользователем в формате чата.
 - Серверный слой включает логику каскада моделей (интерпретация, фильтрация, поиск).
 - Слой данных использует PostgreSQL с расширением pgvector для эффективного хранения и сопоставления векторов.
- Процессы обработки данных:
 - Поток наполнения производит автоматизированный сбор вакансий с rabota.by, их очистку и предварительную векторизацию.
 - Поток поиска включает обработку входящего запроса, извлечение фильтров через LLM и выполнение векторного поиска.




Сбор данных и векторизация

- Сбор данных (Parsing):
 - Источник: портал rabota.by.
 - Сформирован корпус из 1016 вакансий.
 - Автоматизированный парсинг структурированных полей (зарплата, опыт, график, навыки) и полных описаний.
- Модель векторизации:
 - Выбрана мультязычная модель `paraphrase-multilingual-MiniLM-L12-v2`.
 - Обеспечивает баланс между скоростью работы и качеством семантического представления.
- Оптимизация (Weighting):
 - Для борьбы с «размыванием» смысла длинными шаблонами описаний применена авторская схема взвешивания.
 - Ключевые поля повторяются в итоговой строке для усиления их влияния на вектор.


Извлечение структурированных фильтров (LLM-слой)

- Задача LLM-интерпретатора: Преобразовать неструктурированный текст пользователя в набор формальных параметров для базы данных.
- Модель вызывается через API OpenRouter (использована модель inclusionai/ling-2.6-flash).
- Извлекаемые группы фильтров:
 - Опыт работы (experience);
 - График (schedule) и часы работы;
 - Тип занятости и формат (remote/office).
- Обеспечение надежности:
 - Проверка ответа LLM на соответствие схеме JSON и допустимым значениям из БД.
 - Механизм Retry до 3-х попыток повторного запроса с передачей описания ошибки обратно в модель при сбое формата.



Алгоритм релаксации фильтров

- Проблема «нулевой выдачи»:
 - При вводе множества строгих условий (например: удаленно + без опыта + гибкий график + высокая зарплата) выборка в базе данных может стать пустой.
- Решение — Мягкая деградация условий:
 - Разработан жадный алгоритм релаксации, который пошагово снимает наименее важные ограничения до тех пор, пока не будет найдено достаточное количество вакансий.
- Приоритезация фильтров:
 - Каждому полю присвоен вес.
 - Защищенные фильтры (опыт, вид занятости) удаляются в последнюю очередь.
 - Второстепенные параметры (формат оплаты, график) удаляются первыми.



Гибридное ранжирование: Domain Boost

- Один лишь векторный поиск (SBERT) может путать вакансии из смежных областей из-за схожести описаний.
- Решение – Domain Boost:
 - Извлечение доменов с использованием LLM на этапе фильтрации.
 - Использование словаря доменных ключевых слов (IT, Ногеса, Логистика).
 - Подсчет совпадений ключевых слов в названии и навыках.
- Механизм: Небольшая корректировка («буст») итогового расстояния. Если домен совпал – вакансия поднимается выше в выдаче.
- Результат: Повышение точности без использования тяжелых и медленных Cross-моделей.


Векторный поиск и итоговая оценка

- Этап 1: Построение вектора запроса пользователя той же моделью MiniLM.
- Этап 2: Вычисление косинусного расстояния в БД PostgreSQL (pgvector).
- Этап 3: Применение формулы итогового балла:

$$FinalDistance = CosineDistance - (DomainBoostStep * Matches)$$

- Вывод: Получение Top-5 наиболее релевантных вакансий, прошедших через все «сита» (фильтры, релаксацию и буст).

Итоговый пайплайн обработки запроса



Тестирование: Сценарий поиска работы в сфере общественного питания («Бариста без опыта»)



Ищу работу бариста в сеть кофеен, без опыта



Нашел наиболее релевантные вакансии под ваш запрос.
Найдено вакансий: 2.

Вакансия 1

Бариста

Компания: ИП Христинченко Татьяна Петровна

Зарплата: Не указано

Частота выплат: Не указано

Занятость: Полная занятость

Формат найма: Не указано

График: 3/2 или 2/2

Часы работы: Не указано

Формат работы: На месте работодателя

Опыт: Не требуется

Навыки: Общественное питание, Обслуживание покупателей, Контроль сроков годности

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска в высококвалифицированных IT-доменах («Бизнес-аналитика»)



Хочу работать в сфере разработки ПО или бизнес аналитики, опыта нет



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 1.

Вакансия 1

Бизнес-аналитик/Специалист по внедрению ПО

Компания: ООО МигСофт

Зарплата: От 1 700 Вт за месяц на руки

Частота выплат: Два раза в месяц

Занятость: Полная занятость

Формат найма: Не указано

График: 5/2

Часы работы: 8

Формат работы: На месте работодателя или удалённо

Опыт: 1 3 года

Навыки: Деловая коммуникация, 1С: Бухгалтерия, Бизнес-анализ, Аналитическое

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска по специфическим квалификациям и условиям («Водитель с категорией В»)



У меня есть права категории В. Хотел бы работать "на транспорте" – перевозить людей или грузы. График желательно гибкий с почасовой оплатой



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 1.

Вакансия 1

Водитель Такси (Гродно и Гродненская область)

Компания: ООО Матурхан

Зарплата: От 2 000 Br за месяц на руки

Частота выплат: Раз в неделю

Занятость: Полная занятость

Формат найма: Трудовой договор

График: Свободный

Часы работы: Вечерние или ночные смены, 8 или 12

Формат работы: Разъездной, Права категории В

Опыт: Не требуется

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2



Тестирование: Сценарий поиска удаленной работы в IT-сфере («Стажер в IT / Рекрутинг»)



Хочу несложную удаленную работу в IT-сферах: маркетинг, копирайтинг, ... Опыта нет.



Нашел наиболее релевантные вакансии под ваш запрос.

Найдено вакансий: 2.

Вакансия 1

Специалист по подбору персонала в IT сфере (стажер)

Компания: ООО Брайт Эйдженси

Зарплата: От 390 до 650\$ за месяц до вычета налогов

Частота выплат: Не указано

Занятость: Полная занятость

Формат найма: Не указано

График: 5/2

Часы работы: 8

Формат работы: Удалённо

Опыт: Не требуется

Например: Ищу работу бариста в сеть кофеен, без опыта, 2/2




Количественная оценка качества поиска

- Методика оценки (Benchmark):
 - Для тестирования подготовлено 16 контрольных запросов, охватывающих типичные сценарии (IT-вакансии, сфера услуг, логистика, студенческие стажировки).
 - Для каждого запроса вручную определен эталонный набор ключевых слов и ожидаемая профессиональная роль.
- Используемые метрики:
 - hit@1: наличие релевантной вакансии на первой позиции выдачи.
 - hit@5: наличие хотя бы одной релевантной вакансии в топ-5 результатов.
 - Среднее косинусное расстояние: показатель семантической «плотности» соответствия запроса и результата.

Итоговые оценки

- hit@1: 14/16 (87.5%).
- hit@5: 14/16 (87.5%).
- Avg Distance (top-1): 0.5017



Сценарий запроса	Топ-1 результат	hit@1	hit@5	Комментарий
ПВЗ, Wildberries/ Ozon, работа на месте	Менеджер пункта выдачи заказов Wildberries (Лиможа)	Да	Да	Релевантная роль найдена сразу на первой позиции.
Бариста / кофейня / без опыта	Бариста "Джезва"	Да	Да	Точное совпадение по роли и домену horeca.
Support / help desk / удаленно	Support Specialist (Help Desk Analyst)	Да	Да	Точное совпадение по роли и формату работы.
HR / junior / стажировка	Intern/Junior Salesforce Developer	Нет	Нет	найдена смежная junior-роль, но не HR/ подбор.

Заключение

- Результаты работы:
 - Разработан и протестирован работоспособный прототип интеллектуальной системы семантического поиска вакансий.
 - Реализован полный технологический цикл: от автоматизированного сбора данных с `rabota.by` до семантической интерпретации запросов с помощью LLM.
 - Система успешно решает проблему «лексического разрыва», обеспечивая точность `hit@1` на уровне 87.5%.
- Перспективы развития:
 - Переход к двухступенчатой схеме (Retrieval для скорости + Reranking для точности).
 - Разработка полноценной RAG-системы (добавление модуля generative).
 - Интеграция дополнительных источников данных и переход к мультиресурсному поиску.
 - Дообучение (Fine-tuning) моделей эмбеддингов на специфическом корпусе вакансий для лучшего понимания профессиональной терминологии.

Спасибо за внимание!